



HIGHER NORMAL SCHOOL FOR TECHNICAL
EDUCATION OF MOHAMMED VI
HASSAN II UNIVERSITY OF CASABLANCA

Master 2 : Systèmes Distribués et Intelligence Artificielle

Rapport de fin de module

CI/CD pour Machine Learning avec CML

Réalisé par :

- **M. Mohamed Amine GHAZOU**
- **M. Abdelmonaim AHDOUN**

Encadrant:

- **M. Soufiane HAMIDA**

ANNÉE UNIVERSITAIRE : 2025-2026

Table des matières

1. Introduction	15
2. Contexte du projet.....	15
a) Objectif du module	
b) Problématique abordée	
3. Environnement et outils utilisés	15
a) Outils principaux	
b) Outils secondaires	
c) Description de l'environnement	
4. Workflow CI/CD mis en place.....	16
a) Description du pipeline	
b) Etapes principales	
c) Intégration de CML	
d) Exemple de workflow GitHub Actions	
e) Module d'entraînement du modèle	
5. Résultats	17
a) Modèle entraîné	
b) Exemple de rapport généré	
c) Performances obtenues	
6. Conclusion.....	17

1- Introduction :

Ce projet consiste à automatiser l'ensemble du processus d'entraînement d'un modèle de Machine Learning.

Chaque fois que du code est modifié puis envoyé sur GitHub, un entraînement s'exécute automatiquement grâce à GitHub Actions.

L'outil CML permet ensuite de générer automatiquement des métriques, des graphiques et un rapport intégré directement dans les Pull Requests.

Cette approche facilite la comparaison des expériences, améliore le suivi des modèles et permet un workflow plus rapide, clair et organisé.

2- Contexte du projet :

a) Objectif du module :

L'objectif principal est de mettre en place un workflow CI/CD complet appliqué au Machine Learning.

Le module nous apprend à :

- ✓ automatiser les entraînements,
- ✓ générer des rapports automatiques,
- ✓ comparer facilement différentes expériences,
- ✓ organiser un projet ML de manière reproductible et fiable.

b) Problématique abordée :

Dans les projets ML, il peut être difficile de suivre les expériences, de comparer les modèles ou encore de reproduire les résultats. Ce projet répond à la question : *Comment automatiser l'entraînement, le reporting et la comparaison des modèles afin de gagner du temps et de rendre les expérimentations plus fiables ?*

3- Environnement et outils utilisés :

a) Outils principaux :

- **Git / GitHub** : gestion de versions et hébergement.
- **CML (Continuous Machine Learning)** : génération automatisée de rapports dans les Pull Requests.
- **Docker** : exécution reproductible des scripts d'entraînement.

b) Outils secondaires :

- **GitHub Actions** : automatisation du workflow CI/CD.
- **Python** : langage utilisé pour l'entraînement.
- **scikit-learn** : création des modèles ML.

- **matplotlib** : visualisation des résultats.

c) Description de l'environnement :

Le fonctionnement global :

1. Le code est versionné sur GitHub.
2. Un commit ou une Pull Request déclenche le pipeline CI/CD.
3. Docker installe les dépendances et exécute les scripts Python.
4. CML publie automatiquement un rapport dans la Pull Request.

4- Workflow CI/CD mis en place :

a) Description du pipeline :

Le pipeline entraîne automatiquement le modèle à chaque modification du code. GitHub Actions lance un environnement Docker dans lequel s'exécutent les scripts Python d'entraînement et d'évaluation. Les métriques et graphiques sont ensuite publiés dans la Pull Request via CML.

b) Étapes principales :

- Installation des dépendances.
- Exécution du script d'entraînement.
- Génération des métriques et visualisations.
- Publication automatique du rapport CML.

c) Intégration de CML dans la Pull Request :

CML permet de :

- générer un rapport Markdown,
- afficher les graphiques directement dans la PR,
- faciliter la comparaison des expériences.

« *npx cml-send-comment report.md --token \$CML_TOKEN* »

d) Exemple de workflow GitHub Actions :

```
« name: Train ML Model
on:
push:
branches: [ main, develop ]
pull_request:
branches: [ main ]
jobs:
```

```
train-and-report:
runs-on: ubuntu-latest
steps:
- uses: actions/checkout@v4
- uses: actions/setup-python@v4
with:
python-version: '3.10'
- run: pip install -r requirements.txt
- run: python src/train.py
- uses: iterative/setup-cml@v3
- run: python src/evaluate.py
- run: npx cml-send-comment report.md --token $CML_TOKEN »
```

e) Module d'entraînement du modèle :

Le script train.py :

- charge les paramètres depuis params.yaml,
- prétraite les données,
- entraîne un modèle (Random Forest).
- calcule les métriques.
- génère les visualisations,
- sauvegarde les résultats pour le rapport.

Extrait :

```
« model = train_model(X_train, y_train, model_type, model_params)

metrics = calculate_metrics(y_test, model.predict(X_test))

save_metrics(metrics)

plot_predictions(y_test, model.predict(X_test)) »
```

5- Résultats :

a) Modèle entraîné :

Modèle : Random Forest Regressor sur le dataset Kaggle House Prices

Configuration finale :

```
type: random_forest
n_estimators: 100
max_depth: 15
min_samples_split: 5
random_state: 42
```

b) Exemple de rapport généré :

```
data:
  path: 'data/train.csv'
  test_size: 0.2
  random_state: 42
  target: 'SalePrice'

model:
  type: 'random_forest' # Random Forest
  params:
    # Random Forest params optimisés pour meilleures performances
    n_estimators: 250 # Plus d'arbres = meilleure performance (mais plus lent)
    max_depth: 20 # Profondeur augmentée pour capturer plus de patterns
    min_samples_split: 5 # Évite l'overfitting avec des splits plus stricts
    min_samples_leaf: 2 # Chaque feuille doit avoir au moins 2 échantillons
    max_features: 'sqrt' # Utilise sqrt(n_features) pour plus de diversité
    bootstrap: true # Bootstrap pour réduire la variance
    max_samples: 0.8 # Utilise 80% des données par arbre pour plus de robustesse
    random_state: 42
    n_jobs: -1 # Utilise tous les CPU disponibles

training:
  cv_folds: 5
  verbose: 1

evaluation:
  metrics:
    - mae
    - r2
  generate_plots: true
```

 experiment/test-params-v12 had recent pushes 11 seconds ago Compare & pull request

 Your main branch isn't protected
Protect this branch from force pushing or deletion, or require status checks before merging. [View documentation.](#) Dismiss Protect this branch

 main  13 Branches  0 Tags Add file <> Code

 amine-ghazoui update 

399fcfa · 2 minutes ago  20 Commits

	.github/workflows	update	yesterday
	data	initial ML CI/CD stup with working model	3 days ago
	src	modification train.yaml et evaluate.py et train.py	2 days ago
	tests	initial ML CI/CD stup with working model	3 days ago
	.gitignore	initial ML CI/CD stup with working model	3 days ago
	Dockerfile	initial ML CI/CD stup with working model	3 days ago
	PROJECT_DOCUMENTATION.md	update	yesterday
	params.yaml	update	2 minutes ago
	requirements.txt	initial ML CI/CD stup with working model	3 days ago

 README



Some checks haven't completed yet

10 in progress checks

- Experiment Matrix / matrix-experiments (50, 10) (pull_request) Started now — This check has started... ...
- Experiment Matrix / matrix-experiments (50, 15) (pull_request) Started now — This check has started... ...
- Experiment Matrix / matrix-experiments (50, 20) (pull_request) Started now — This check has started... ...
- Experiment Matrix / matrix-experiments (100, 10) (pull_request) Started now — This check has started... ...
- Experiment Matrix / matrix-experiments (100, 15) (pull_request) Started now — This check has started... ...
- Experiment Matrix / matrix-experiments (100, 20) (pull_request) Started now — This check has started... ...
- Experiment Matrix / matrix-experiments (200, 10) (pull_request) Started now — This check has started... ...
- Experiment Matrix / matrix-experiments (200, 15) (pull_request) Started now — This check has started... ...



No conflicts with base branch

Merging can be performed automatically.

Merge pull request

You can also merge this with the command line. [View command line instructions.](#)

Still in progress? [Convert to draft](#)



All checks have passed

11 successful checks

- Experiment Matrix / matrix-experiments (50, 10) (pull_request) Successful in 34s ...
- Experiment Matrix / matrix-experiments (50, 15) (pull_request) Successful in 36s ...
- Experiment Matrix / matrix-experiments (50, 20) (pull_request) Successful in 29s ...
- Experiment Matrix / matrix-experiments (100, 10) (pull_request) Successful in 31s ...
- Experiment Matrix / matrix-experiments (100, 15) (pull_request) Successful in 30s ...
- Experiment Matrix / matrix-experiments (100, 20) (pull_request) Successful in 35s ...
- Experiment Matrix / matrix-experiments (200, 10) (pull_request) Successful in 33s ...
- Experiment Matrix / matrix-experiments (200, 15) (pull_request) Successful in 31s ...



No conflicts with base branch

Merging can be performed automatically.

Merge pull request

You can also merge this with the command line. [View command line instructions.](#)

Still in progress? [Convert to draft](#)



Rapport d'Entraînement ML

Commit: cda1ec6f6d59a90e3785b3c1f22f40b187468d58

Auteur: @amine-ghazoui

Branche: experiment/test-params-v17



Métriques du Modèle

Métrique	Valeur
MAE	14780.67
R ²	0.8563



Comparaison avec Baseline

Rapport de comparaison des modèles


Métriques





Métrique	Baseline	Actuel	Amélioration
MAE	17305.0396	14780.6666	✅ +14.59%
R2	0.8366	0.8563	✅ +2.35%

Analyse

📊 Le modèle actuel montre une amélioration moyenne de 8.47%.

- MAE: Amélioration significative (+14.59%)
- R2: Légère amélioration (+2.35%)





c) Performances obtenues :

 Rapport des expériences ML

Date: 2025-12-13 13:39:39

 Résultats des expériences

 Tous les résultats

Modèle	N_estimators	Max_depth	MAE	R ²
random_forest	200	20	14667.9	0.8584
random_forest	100	20	14725	0.8605
random_forest	200	15	14826.3	0.8558
random_forest	200	10	14930	0.8577
random_forest	100	15	14976.3	0.8536
random_forest	100	10	14996.5	0.8567
random_forest	50	10	14997.3	0.8577
random_forest	50	20	15009.5	0.8559
random_forest	50	15	15170.1	0.85

 Meilleur modèle

- **Modèle:** random_forest
- **N_estimators:** 200
- **Max_depth:** 20
- **MAE:** 14667.89
- **R²:** 0.8584

 Résumé CSV

```
Modèle,N_estimators,Max_depth,MAE,R2
random_forest,200,20,14667.89,0.8584
random_forest,100,20,14724.97,0.8605
random_forest,200,15,14826.33,0.8558
random_forest,200,10,14929.95,0.8577
random_forest,100,15,14976.33,0.8536
random_forest,100,10,14996.54,0.8567
random_forest,50,10,14997.32,0.8577
random_forest,50,20,15009.48,0.8559
random_forest,50,15,15170.09,0.85
```



6- Conclusion :

Ce projet a permis de mettre en place avec succès un workflow CI/CD complet pour le Machine Learning. L'automatisation via GitHub Actions et CML a démontré son efficacité : entraînements automatiques, rapports visuels dans les PR, et identification rapide de la meilleure configuration ($R^2=0.837$) via matrice d'expériences.

Les compétences MLOps acquises (GitHub Actions, CML, pipelines automatisés) constituent une base solide pour industrialiser tout projet ML. Le gain en reproductibilité, traçabilité et temps de développement est significatif.

Les perspectives incluent l'ajout de tests automatisés, le déploiement continu et le monitoring en production. Ce workflow démontre concrètement comment les pratiques DevOps appliquées au ML professionnalisent l'expérimentation et facilitent la collaboration en Data Science.